علی عباسی

AI / GenAI Engineer

+39 379 230 8299 | abbasialiar@gmail.com | aliarabbasi5155.github.io | aliarabbasi5155 | aliabbasi5155 | Google Scholar

خلاصه

AI / GenAI Engineer و Technical Lead هستم، با بیش از ۵ سال سابقه‌ی توسعه‌ی نرم‌افزار، و هنوز خودم هم مستقیم کد می‌زنم. کارم را به‌عنوان Fullstack Developer شروع کردم و حالا تمرکزم روی ساخت و راه‌اندازی سیستم‌های GenAI در production است. مسئولیت محصولات مبتنی بر LLM را از ابتدا تا انتها بر عهده می‌گیرم: از طراحی راه‌حل و معماری agentic RAG گرفته تا fine-tuning، ارزیابی (evaluation) و deploy پایدار روی AWS با سرویس‌های containerized، CI/CD و مانیتورینگ production.

تجربه‌ی پژوهش کاربردی را با مسئولیت تحویل محصول ترکیب می‌کنم؛ تیم‌های کوچک را هدایت می‌کنم و نیازهای مبهم stakeholderها را به سیستم‌های AI قابل‌اتکا در production تبدیل می‌کنم. پیشینه‌ام همچنین Reinforcement Learning، Computer Vision و پژوهش کاربردیِ منتشرشده را در بر می‌گیرد.

سوابق کاری

AI Engineer و Team Lead (پاره‌وقت، دورکاری)

لندن، بریتانیا

Primentoring.AI

نوامبر ۲۰۲۵ – اکنون

- هدایت یک تیم دونفره‌ی مهندسی از ابتدا تا انتها، با مسئولیت solution architecture، بررسی امکان‌سنجی، گزارش سلامت پروژه و هماهنگی با stakeholderها در تیم‌های محصول، QA و نرم‌افزار.
- معماری Dana AI، یک agent چندوجهی (multimodal) و real-time با 3D talking head، صدا و متن روی WebSocket: OmniTalker برای lip-sync (fine-tune) شده با LoRA برای هر منتور، روی GPT-4o Transcribe (AWS SageMaker)، برای ASR با vocabulary hints، و GPT-4.1 که روی پلتفرم OpenAI برای لحن و پرسونای منتور fine-tune شده است؛ با time-to-first-frame حدود ۲٫۵ ثانیه برای پاسخ ویدیویی.
- طراحی یک agentic RAG stack در production روی Weaviate با مدیریت داخلی (AWS EC2): latency بازیابی حدود ۹۰۰ میلی‌ثانیه، hybrid search، query expansion، reranking، agentهای مبتنی بر function calling، task decomposition و حافظه‌ی مکالمه‌ای و بلندمدت با LangGraph (دقت بازیابی top-5 حدود ۸۷٪). همین stack بعداً ستون اصلی یک LLM Customer Support Chatbot روی اسناد شرکت شد.
- ساخت قابلیت Public Data Aggregation که سیگنال‌های منتورها را به‌صورت موازی از ۸ پلتفرم استخراج می‌کند؛ هر دور جمع‌آوری حدود ۳ دقیقه طول می‌کشد و محدودیت‌های ToS هر سرویس و GDPR رعایت می‌شود.
- ساخت یک evaluation suite مبتنی بر RAGAS با ۱۰۰ query منتخب از حوزه‌ی منتورینگ، به‌همراه guardrailها، فیلتر PII، confidence scoring، ارجاع human-in-the-loop، ردگیری prompt و نسخه، و یک Unanswered Pool با حلقه‌ی بسته که queryهای کم‌اطمینان را به منتورها می‌سپارد و پاسخ‌هایشان را دوباره به knowledge base برمی‌گرداند.
- ساخت یک recommender system که سیگنال‌های رفتاری (مهارت‌ها، میزان مشارکت، talk-time و احساسات) را از جلسه‌های منتورینگ استخراج می‌کند تا برای هر mentee منتور مناسب پیدا کند.
- عملیاتی‌کردن همه‌ی سرویس‌های AI به شکل microserviceهای Django/Celery روی EC2 با Redis، PostgreSQL، ETL pipelineها، CI/CD با GitHub Actions که زمان deploy را به حدود ۱٫۵ دقیقه رساند، و مانیتورینگ با Prometheus و Grafana.

Machine Learning Engineer و Fullstack Developer

تورین، ایتالیا

Nimbus SRL

فوریه ۲۰۲۲ – اکنون

- ساخت و راه‌اندازی یک دستیار پشتیبانی داخلی مبتنی بر LLM (LangChain RAG روی Llama-3-8B که با LoRA روی AWS SageMaker به‌صورت اختصاصی fine-tune شده و به اسناد داخلی شرکت متکی است)؛ این دستیار حالا هفته‌ای بیش از ۱٬۲۰۰ query را پاسخ می‌دهد.
- کوتاه‌کردن onboarding مهندس‌های جدید از چند هفته به ۲ تا ۳ روز، با در دسترس گذاشتن مدل fine-tuneشده از طریق یک رابط چت داخلی متصل به knowledge base شرکت.
- طراحی یک کنترلر Reinforcement Learning مبتنی بر PPO برای پایدارسازی autopilot پهپادهای VTOL در آب‌وهوای نامساعد، که نرخ موفقیت recovery را در شبیه‌سازی‌های پرواز آزمایشی ۵٪ بهبود داد.
- هدایت یک تیم چهارنفره‌ی مهندسی برای ساخت یک سیستم cross-platform مانیتورینگ ناوگان روی AWS، با telemetry دوثانیه‌ای برای بیش از ۱۵۰ پهپاد (UAV) در سراسر اروپا.
- مدرن‌سازی stack نرم‌افزاری (React Native، Django REST Framework، CI/CD و deploymentهای containerized) که با کم کردن ظرفیت مهندسی لازم برای نگهداری و توسعه‌ی پلتفرم، سالانه حدود ۵۰٬۰۰۰ یورو صرفه‌جویی کرد.
- مشارکت در پروژه‌ی Charger Box برای خودکارسازی جابه‌جایی پهپادها جهت شارژ خودکار، با ۹۸٪ docking موفق.

Machine Learning Engineer و Fullstack Developer

تورین، ایتالیا

Reefilla SRL

سپتامبر ۲۰۲۱ – فوریه ۲۰۲۲

- طراحی و deploy یک مدل recommender که زمان بهینه‌ی درخواست power bank برقی را پیش‌بینی می‌کند و سرعت پاسخ‌گویی در تحویل را حدود ۱۸٪ بهبود داد.
- توسعه‌ی مشترک یک اپلیکیشن cross-platform (React Native + Django) برای مدیریت شارژ خودروهای برقی (EV) که تا پایان ۲۰۲۱ به بیش از ۸۰۰ کاربر فعال رسید.

سوابق قبلی

Backend Developer | استارتاپ Bardal | تهران، ایران | ژوئیه ۲۰۱۹ – ژانویه ۲۰۲۰ | Django، DRF، REST API، Docker، Kubernetes، PostgreSQL

Frontend Developer | استارتاپ Spinzer | تهران، ایران | نوامبر ۲۰۱۸ – ژوئن ۲۰۱۹ | ReactJS، TypeScript، Redux، HTML/CSS

Backend Developer (کارآموزی) | Saaed Co. | اراک، ایران | ژوئن ۲۰۱۸ – اکتبر ۲۰۱۸ | .Net، REST API، HTML/CSS، JS

پروژه‌ها

Local Image Studio؛ ساخت و ویرایش خصوصی تصویر با AI

پروژه‌ی شخصی — اکتبر ۲۰۲۶ – نوامبر ۲۰۲۶

- استودیوی self-hosted و Open Source برای ساخت و ویرایش تصویر روی GPU خود کاربر، بر پایه‌ی FLUX.2 Klein 9B و SAM 3 و ComfyUI: روی Apple Silicon با MLX و روی GPUهای NVIDIA از ۶ گیگابایت VRAM با GGUF و CUDA. نصب با یک دستور و deploy با Docker Compose.
- ساخت تصویر از متن، ویرایش با دستور متنی و ویرایش ناحیه‌ای با maskهای خودکار SAM 3 و محافظت از چهره، بازسازی جزئیات با Close-up، جابه‌جایی سر یا کل آدم و ساخت ویدیو از عکس با LTX-2.3. هر job بعد از restart هم از دست نمی‌رود و هر تصویر recipe قابل‌بازتولید خودش را نگه می‌دارد.
- patch کردن pipeline مبتنی بر MLX برای آزاد کردن text encoder و transformer بین مراحل، که زمان ساخت یک تصویر ۱۰۲۴ × ۱۰۲۴ را با pixelهای کاملاً یکسان از ۱۸۴ به ۷۶ ثانیه رساند. Engine فقط هنگام نیاز روشن می‌شود و بعد از ۱۰ دقیقه بیکاری unload می‌شود.
- اپ PWA قابل نصب روی گوشی با HTTPS از طریق یک home CA با name constraints، ورود با PIN، فرستادن عکس از گالری و کتابخانه‌ی offline.

Vector DB Manager for Weaviate and Qdrant

پروژه‌ی شخصی — مارس ۲۰۲۵

- داشبوردی با Next.js و TypeScript برای مدیریت vector databaseهای Weaviate و Qdrant: عملیات CRUD روی collectionها و objectها، semantic search و hybrid search، متریک‌های زنده و deploy با یک دستور Docker.

Reconstructing Human Gaze Behavior in Stroop Test Using IRL and EEG Data

دانشگاه آلاباما، دانشگاه ایالتی می‌سی‌پی و دانشگاه پلی‌تکنیک تورین — ژوئیه ۲۰۲۴ – دسامبر ۲۰۲۴

- توسعه‌ی یک مدل Inverse Reinforcement Learning (IRL) برای بازسازی رفتار نگاه انسان در آزمون Stroop.
- fine-tune کردن مدل Detectron2 FPN برای feature extraction از تسک‌های Stroop با رزولوشن پایین و بالا.
- استفاده از PPO و GAE درون الگوریتم GAIL.
- تحلیل اثر cognitive load بر الگوهای نگاه و فرایند تصمیم‌گیری.

مدل‌سازی شبکه‌ای همه‌گیری COVID-19 با داده‌های جابه‌جایی GSM و مدل SIR

دانشگاه پلی‌تکنیک تورین — ژانویه ۲۰۲۴ – مارس ۲۰۲۴

- توسعه‌ی یک مدل شبکه‌ای برای شبیه‌سازی هفتگی شیوع COVID-19 با داده‌های جابه‌جایی GSM و مدل SIR.
- استفاده از کتابخانه‌هایی مثل NetworkX، Pandas و NumPy برای پردازش و تحلیل داده.
- استفاده از CUDA برای اجرای HPC و کارآمد مدل SIR روی شبکه‌های بزرگ‌مقیاس.
- تحلیل اثر الگوهای جابه‌جایی بر دینامیک انتقال ویروس.
- پیاده‌سازی سناریوهای مختلف برای سنجش اثربخشی راهبردهای مداخله.

Distributed Learning روی دیتاست CIFAR-100: بررسی Data Parallelism

دانشگاه پلی‌تکنیک تورین — نوامبر ۲۰۲۳ – دسامبر ۲۰۲۳

- پیاده‌سازی الگوریتم‌های distributed machine learning شامل LocalSGD، Distributed SGD، SlowMo و LocalAdaScale روی چند GPU node.
- مقایسه‌ی عملکرد الگوریتم‌ها روی دیتاست CIFAR-100 از نظر سرعت همگرایی، دقت و communication overhead.

مدل تشخیص کلمه‌ی trigger با TFLite

دانشگاه پلی‌تکنیک تورین — اکتبر ۲۰۲۳

- توسعه‌ی مدلی با TFLite و معماری LSTM روی Arduino برای تشخیص کلمه‌ی trigger، با محدودیت ولتاژ و حافظه‌ی کم.

مهارت‌ها

زبان‌های برنامه‌نویسی:
Python، C++، C#، JavaScript، TypeScript، SQL

GenAI و مهندسی LLM:
LangGraph، LangChain، Agentic RAG، Hybrid Search، Reranking، Function Calling، Task Decomposition، Conversational & Long-term Memory، MCP، LoRA، Fine-tuning، OpenAI Fine-tuning Platform، RAGAS، Guardrails، PII Filtering، Prompt Versioning

یادگیری ماشین:
PyTorch، TensorFlow، scikit-learn، Hugging Face، Transformers، Reinforcement Learning، Computer Vision، NLP، WandB، TensorBoard

داده و ذخیره‌سازی:
PostgreSQL، Redis، Weaviate، MySQL، SQLite، ETL Pipelines

Backend و API:
Django، Django REST Framework، Celery، REST، WebSocket، Microservices، Pytest

DevOps و Cloud:
AWS (EC2, SageMaker, S3)، Azure، Docker، Kubernetes، GitHub Actions، GitLab CI، Nginx، Prometheus، Grafana، Linux

Frontend و موبایل:
React.js، React Native، Next.js، Redux، Tailwind CSS

رهبری و همکاری:
رهبری فنی، Solution Architecture، مدیریت stakeholderها، امکان‌سنجی، منتورینگ، Agile/Scrum، Git، Jira، Confluence

تحصیلات

کارشناسی ارشد علوم و مهندسی داده — تورین، ایتالیا
دانشگاه پلی‌تکنیک تورین — ۲۰۲۰ – ۲۰۲۴

- **پایان‌نامه:** «Reconstructing Human Gaze Behavior in Stroop Test from EEG Data Using Inverse Reinforcement Learning»
- **مقاله:** بر پایه‌ی همین پایان‌نامه، در ژورنال Smart Health انتشارات Elsevier (۲۰۲۵) منتشر شد
- **کنفرانس:** همچنین در کنفرانس IEEE/CHASE 2025 پذیرفته شد

کارشناسی مهندسی کامپیوتر — اراک، ایران
دانشگاه اراک — ۲۰۱۵ – ۲۰۱۹

مقالات

Transforming Stroop task cognitive assessments with multimodal Inverse Reinforcement Learning
Ali Abbasi, Jiaqi Gong, Soroush Korivand
Smart Health 36, p. 100567, 2025. Elsevier

علایق

کتاب خواندن شیفته‌ی کتاب‌های نوآوری در کسب‌وکار (مثل اریک ریس) و کتاب‌های درجه‌یک توسعه‌ی فردی (مثل کال نیوپورت) هستم.
فوتبال بیش از حد بازی‌های لیورپول را تماشا می‌کنم و با دوستانم FIFA بازی می‌کنم.
یادگیری همیشه درباره‌ی ترندهای جدید تکنولوژی می‌خوانم یا دوره‌های آنلاین می‌گذرانم؛ این روزها تمرکزم روی ترندهای AI است.
دوچرخه‌سواری شبانه ۳۰ تا ۴۰ دقیقه رکاب زدن در شهر بعد از تاریک شدن هوا؛ راه همیشگی من برای شارژ کامل ذهن و بدن.

زبان‌ها

انگلیسی تسلط حرفه‌ای
فارسی زبان مادری

در صورت درخواست، معرفی‌نامه ارائه می‌شود.